

GO-6 — fizičko-AI benchmark

Multimodalni test tehničkog odlučivanja nad analognim instrumentima, fuzzy logikom i dinamičkom simulacijom

dr Jovan Ivković¹

Metodološki esej / naučni rad — radna verzija za REAL-AI-Benchmark projekat

Verzija: fizičko-multimodalni prošireni nacrt

Methodological essay / scientific paper

1. Email: jovan.ivkovic@its.edu.rs, ORCID: <https://orcid.org/0000-0001-5236-9529>

Ovaj dokument formalizuje GO-6 kao novu klasu benchmarka: ne samo test formalnog računanja, nego test opažanja, mernog intervala, fuzzy procene rizika, simulacije posledica akcija i izvršive programske verifikacije.

Sažetak

GO-6 je proširenje GO benchmark filozofije iz domena čisto tekstualno-formalnih zadataka u domen fizičkog, multimodalnog i odlučivačkog rezonovanja. Test je osmišljen zato što smo želeli da proverimo da li LLM/LMM model može da radi sa realističnijim inženjerskim lancem: da očitava analogne instrumente, prihvati mernu nesigurnost, izvede fuzzy procenu stanja, simulira dinamiku sistema kroz više koraka, klasifikuje posledice svake akcije, izabere jedinstveno najbolju odluku i zatim isti postupak pretoči u proverljiv Zig kod i strukturisan JSON izlaz. Za razliku od standardnih digitalnih zadataka u kojima su ulazne vrednosti već idealno pripremljene, GO-6 namerno uvodi fizičku nepreciznost, prelazne fuzzy zone i konflikt između intuitivno agresivne reakcije i stvarnih dinamičkih posledica. Time se meri sposobnost modela da razmišlja kroz opažanje, kontekst, uzročno-posledični lanac i tehničku proverljivost, a ne samo da proizvede ubedljiv tekst.

Ključne reči: fizičko-AI benchmarkovanje, LMM, analogni instrumenti, fuzzy logika, dinamička simulacija, tehničko odlučivanje, Zig verifikacija, REAL-AI-Benchmark.

Executive summary

GO-6 uvodi analogne instrumente kao ulazni sloj, fuzzy inferenciju kao sloj procene trenutnog rizika i diskretnu dinamičku simulaciju kao sloj izbora akcije. Osnovni metodološki cilj je da se razlikuje model koji samo prepoznaje šablon od modela koji ume da očitava fizičke veličine, računa sa intervalima, ne donosi preuranjenu odluku i razume da najagresivnija akcija nije nužno najbolja. Test je kompatibilan sa dve verzije: GO-6-old-simple-no-VI, gde su ulazi dati digitalno za obične tekstualne LLM-ove, i glavna GO-6 multimodalna verzija, gde model mora da očitava pet slika analognih instrumenata.

1. Uvod: zašto je GO-6 bio potreban

GO-1 do GO-5 su već pokrili formalnu logiku, egzaktnu numeriku, konvolucioni ručni račun, bitmask pretragu, Mealy transduktor, dokaz jedinstvenosti i izvršivi kod. Međutim, svi ti zadaci polaze od teksta u kome su ulazne vrednosti već date u čistom digitalnom obliku. To jeste neophodno za proveru formalne discipline, ali ne pokriva ceo prostor realnog tehničkog odlučivanja.

Zato smo u GO-6 namerno prešli iz sveta savršeno pripremljenih simbola u svet fizičkog opažanja. Ideja nije bila da napravimo još jedan matematički zadatak, nego da jasno proverimo da li model može da radi ono što inženjer ili operater u stvarnom sistemu mora da radi: da pogleda instrument, očita vrednost, prizna da očitavanje ima toleranciju, proceni stanje sistema i tek zatim računa posledice mogućih intervencija.

U takvom lancu greška ne nastaje samo u aritmetici. Ona može nastati već u opažanju. Model može pogrešno pročitati skalu, zanemariti interval, poistovetiti fuzzy upozorenje sa konačnom odlukom, preskočiti dinamičke posledice ili napisati kod koji ne reprodukuje sopstvenu analizu. GO-6 je zato uveden kao fizičko-multimodalni produžetak benchmarka, a ne kao kozmetička varijanta prethodnih testova.

2. Metodološki položaj GO-6 u odnosu na GO-1 do GO-5

GO-6 ne menja osnovnu filozofiju GO seta: i dalje se ocenjuju međukoraci, formalna struktura, kod, JSON i dokazivost rezultata. Ono što menja jeste priroda ulaza i odlučivanja. Model više ne dobija samo tekstualni problem, nego mora da prevede vizuelno-fizičku informaciju u numerički model.

Sloj testa	GO-1 do GO-5	GO-6-old-simple-no-VI	GO-6 multimodalni test
Ulaz	Digitalno dat tekst / matrice / formule	Digitalno date fizičke veličine	Slike analognih instrumenata + tekst pravila
Glavni rizik greške	Formalni račun, logika, kod	Fuzzy račun i dinamika	Očitavanje, interval, fuzzy logika, dinamika i kod
Multimodalnost	Nije obavezna	Nije potrebna	Obavezna
Konačni signal	Tačno rešenje i kod	Tačna fizička odluka	Tačna odluka iz opažanja i simulacije

Tabela 1. Poređenje GO-6 sa prethodnim benchmark slojevima.

3. Arhitektura GO-6 testa

GO-6 je organizovan kao kontrolisani inženjerski problem u kome se sistem nalazi u napetom, ali ne trivijalno katastrofalnom stanju. Pet fizičkih veličina se očitava sa analognih instrumenata: temperatura T, pritisak P, protok F, vibracija V i trend pritiska $D = dP/dt$. Na osnovu tih vrednosti računa se fuzzy rizik, a zatim se simuliraju četiri moguće akcije upravljanja.




Oznaka	Veličina	Uloga u sistemu
T	Temperatura [°C]	Termičko stanje; zavisi od pritiska, protoka i toplotnog efekta akcije H.
P	Pritisak [kPa]	Mehaničko opterećenje; zavisi od trenda D, temperature i rasterećenja R.
F	Protok [L/min]	Hlađenje i transport; menja se akcijom C i utiče na temperaturu.
V	Vibracija [mm/s]	Dinamičko-mehanički kanal; odlučujući je za granice unstable/catastrophic.
D	dP/dt [kPa/min]	Trend pritiska; pokazuje da li sistem sam ide ka pogoršanju ili stabilizaciji.


Tabela 2. Fizičke veličine GO-6 testa i njihova uloga.

4. Analogni instrumenti kao namerni metodološki filter

Analogni instrumenti su uvedeni zato što u realnom fizičkom sistemu merenje nije idealan JSON. Kazaljka na skali zahteva interpolaciju, a interpolacija zahteva interval. Model koji napiše samo jednu digitalnu vrednost bez intervala zapravo preskače važan deo fizičkog problema.

U referentnoj GO-6 instanci slike su imenovane PIC1.png do PIC5.png. U dokumentu su prikazane kao ilustrativni instrumenti; u stvarnom testu se slike ručno prilažu uz prompt, dok se tekstualna postavka drži fiksnom.

Instrument	Očitavanje i interpretacija
 PIC1.png / Temperatura T	Nominalno očitavanje: $T = 68.5\text{ }^{\circ}\text{C}$; interval $[68.0, 69.0]\text{ }^{\circ}\text{C}$.
 PIC2.png / Pritisak P	Nominalno očitavanje: $P = 132.0\text{ kPa}$; interval $[131.0, 133.0]\text{ kPa}$.
 PIC3.png / Protok F	Nominalno očitavanje: $F = 4.2\text{ L/min}$; interval $[4.0, 4.4]\text{ L/min}$.



Slika 1. Referentni analogni instrumenti GO-6 testa. Slike u dokumentu predstavljaju radnu vizuelnu osnovu za multimodalnu verziju benchmarka.

5. Fizičke jednačine i dinamički model

Dinamički model je namerno mali, ali kauzalno gust. Svaka akcija ima četiri parametra: H za termički efekat, R za rasterećenje pritiska, S za vibracioni udar i C za promenu protoka. Stanje se ažurira kroz tri takta i svaki takt koristi prethodno stanje, što znači da se greške u proračunu propagiraju.

$$\begin{aligned} T_{next} &= T + 0.18 * (P - 120) - 0.75 * F + H \\ P_{next} &= P + D + 0.12 * (T - 65) - R \\ V_{next} &= V + 0.08 * (P - 125) + S \\ F_{next} &= F + C \end{aligned}$$

Akcija	Naziv	H	R	S	C
A0	MONITOR	+2.0	0.0	+0.2	0.0
A1	DERATE	+0.5	1.0	+0.1	+0.4
A2	CONTROLLED_RELIEF	-0.5	4.0	+0.3	+0.8
A3	EMERGENCY_MODE	-2.0	9.0	+1.8	-1.5

Tabela 3. Parametri akcija u GO-6 modelu.

6. Fuzzy inferencija: procena rizika, ali ne i konačna odluka

Fuzzy sloj je uveden zato što fizičke veličine u prelaznim zonama nisu prirodno binarne. Temperatura može biti delimično normalna i delimično visoka; pritisak može biti u prelazu između normalnog i visokog; vibracije mogu biti već nestabilne, ali još ne katastrofalne. Zato se koriste stepeni pripadnosti i Mamdani min-max pravila.

Za referentne nominalne vrednosti dobijaju se sledeći ključni stepeni pripadnosti:

Veličina	Fuzzy skup	Stepen pripadnosti
T	normal	0.100
T	high	0.900
T	critical	0.000
P	normal	0.150
P	high	0.850
P	critical	0.000
F	low	0.400
F	adequate	0.600
V	stable	0.000
V	unstable	0.640
D	steady	0.000
D	rising_fast	0.550

Tabela 4. Referentne fuzzy pripadnosti za GO-6 nominalna očitavanja.

Aktivacije pravila računaju se min-max logikom:

```
R1 = min(high(T), high(P)) = min(0.900, 0.850) = 0.850
R2 = min(high(P), rising_fast(D)) = min(0.850, 0.550) = 0.550
R3 = min(low(F), high(T)) = min(0.400, 0.900) = 0.400
R4 = min(unstable(V), high(P)) = min(0.640, 0.850) = 0.640
R5 = max(critical(T), critical(P)) = 0.000
aggregated_risk = max(R1,R2,R3,R4,R5) = 0.850
initial_fuzzy_decision = EMERGENCY_MODE
```

Ključna metodološka tačka je da ova odluka nije konačna akcija. Ona je samo procena trenutnog rizika. Konačna akcija mora se dobiti iz simulacije posledica, jer agresivna intervencija može proizvesti sekundarni rizik.

7. Simulacija posledica i izbor akcije

GO-6 namerno razdvaja upozorenje od upravljanja. Ako je rizik visok, to ne znači da je najagresivnija akcija najbolja. U referentnom scenariju upravo EMERGENCY_MODE, iako intuitivno privlačan, proizvodi katastrofalnu vibraciju.

Akcija	T3	P3	F3	V3	Ishod	max rel. excess
A0 MONITOR	72.913	139.978	4.200	8.494	catastrophic	0.213499
A1 DERATE	66.940	136.380	5.400	7.940	unstable	0.134299
A2 CONTROLLED_RELIEF	61.399	126.920	6.600	7.810	unstable	0.115785
A3 EMERGENCY_MODE	59.341	111.479	-0.300	11.096	catastrophic	1.085714

Tabela 5. Nominalni dinamički ishodi posle tri takta.

Po kriterijumu izbora prvo se eliminišu catastrophic akcije. Zatim se traži safe akcija. Ako safe akcija ne postoji, bira se unstable akcija sa najmanjim maksimalnim relativnim prekoračenjem bezbednosnih granica. U referentnom slučaju A1 i A2 su unstable, ali A2 ima manji relativni višak vibracije iznad granice V = 7.

```
excess(A1) = (7.940096 - 7) / 7 = 0.134299
excess(A2) = (7.810496 - 7) / 7 = 0.115785
0.115785 < 0.134299 => recommended_action = CONTROLLED_RELIEF
```

8. Šta se GO-6 testom validira

Validacioni sloj	Šta se meri
Vizuelno očitavanje	Model mora da prepozna skalu, položaj kazaljke i približnu vrednost, uz razuman interval nesigurnosti.

Merna nesigurnost	Ne traži se lažna preciznost, već tehnički razumna kombinacija nominalne vrednosti i intervala očitavanja.
Fuzzy rezonovanje	Model mora da računa sa stepenima pripadnosti i pravilima min-max logike, a ne samo sa tvrdim if/else granicama.
Kauzalna dinamika	Model mora da propagira stanje kroz tri takta i da ne koristi stare vrednosti u kasnijim koracima.
Odlučivanje pod konfliktom	Model mora da prepozna da najviši inicijalni rizik ne znači automatski izbor najagresivnije akcije.
Proverljivost koda	Zig kod mora da reprodukuje fuzzy i dinamički sloj, a ne samo da ispiše unapred poznat rezultat.

Tabela 6. Validacioni slojevi GO-6 testa.

9. Tipične greške modela i očekivani failure modes

GO-6 je konstruisan tako da razotkrije više slabosti koje se često ne vide na širokim, ali slabije kontrolisanim benchmarkovima. Najčešće greške očekujemo u sledećim zonama:

Klasa greške	Primer	Uticaj na ocenu
Pogrešno očitavanje	Kazaljka pritiska se pročitaa kao 128 kPa ili 138 kPa umesto oko 132 kPa.	Utiče na A i dalje na C/D.
Bez intervala	Model navede samo T=68.5 bez intervala i komentara o analognoj nesigurnosti.	Smanjuje A i metodološku zrelost.
Fuzzy shortcut	Model iz aggregated_risk=0.850 direktno bira EMERGENCY_MODE.	Velika greška u E.
Simulacioni drift	U drugom taktu se koristi početni P umesto P1 ili se ne ažurira F.	Velika greška u D.
Ignorisanje vibracija	Model smatra da je A3 dobar jer snižava temperaturu i pritisak, ali prevede V3>8.	Kritična odluka.
Neizvršiv Zig	Kod je pseudokod ili koristi nekompatibilan I/O obrazac za ciljnu Zig verziju.	Gubitak F poena.

Tabela 7. Tipične greške i njihova interpretacija.

10. Predložena rubrika bodovanja

GO-6 treba oceniti sabiranjem postignuća po elementima. Ne uvodi se proizvoljno pravilo da jedan neuspešan element automatski obara ceo rezultat na nisku ocenu. Ako je model odličan u opažanju i odluci, ali ima manje Zig greške, gubi bodove iz kodnog dela. Ako kod radi, ali je konačna odluka pogrešna, kod ne može spasiti ukupnu ocenu.

Sekcija	Element ocene	Poeni / 100
A	Očitavanje pet analognih instrumenata, nominalne vrednosti, intervali i kratko obrazloženje	15
B	Fizička konzistentnost i razumevanje konflikta između kanala sistema	10
C	Fuzzy pripadnosti, aktivacije pravila, aggregated_risk i inicijalna fuzzy odluka	20
D	Dinamička simulacija sve četiri akcije kroz tri takta i tačna klasifikacija ishoda	20
E	Konačna odluka, izbor A2, dokaz jedinstvenosti i objašnjenje zašto fuzzy odluka nije konačna	15
F	Zig kod: algoritam, kompatibilnost, JSON izlaz i reprodukcija rezultata	15
G	Format, sekcije, RESULTS_JSON i završni <END> marker	5

Tabela 8. Predložena rubrika bodovanja GO-6 testa.

11. Kompaktni referentni Zig snipeti

U nastavku nisu dati svi detalji finalnog programa, nego referentni snipeti koji pokazuju šta se u kodu mora zaista implementirati. Pun odgovor modela treba da implementira kompletne fuzzy funkcije, sve akcije, simulaciju, klasifikaciju, izbor i RESULTS_JSON.

```
const State = struct { T: f64, P: f64, F: f64, V: f64 };
const Action = struct { name: []const u8, index: i32, H: f64, R: f64, S: f64, C: f64 };

fn simulate(s0: State, dPdt: f64, a: Action) [3]State {
    var states: [3]State = undefined;
    var s = s0;
    for (0..3) |i| {
        const next = State{
            .T = s.T + 0.18 * (s.P - 120.0) - 0.75 * s.F + a.H,
            .P = s.P + dPdt + 0.12 * (s.T - 65.0) - a.R,
            .V = s.V + 0.08 * (s.P - 125.0) + a.S,
            .F = s.F + a.C,
        };
        states[i] = next;
        s = next;
    }
    return states;
}

fn maxRelativeExcess(s: State) f64 {
    return max4(
        max(0.0, (s.T - 78.0) / 78.0),
        max(0.0, (s.P - 142.0) / 142.0),
        max(0.0, (s.V - 7.0) / 7.0),
        max(0.0, (3.5 - s.F) / 3.5),
    );
}
```

12. GO-6-old-simple-no-VI kao kontrolna varijanta

Digitalna verzija GO-6, označena kao GO-6-old-simple-no-VI, služi za testiranje modela koji nemaju vizuelne sposobnosti. U toj verziji se instrumenti ne prilažu kao slike, već se ulazne vrednosti daju direktno u tekstu. Ta verzija meri fuzzy-dinamičku odluku, ali ne meri vizuelno očitavanje. Zbog toga se rezultati ne smeju mešati bez oznake. Multimodalna verzija ima veći evaluacioni opseg i treba je tretirati kao glavni GO-6 test.

13. Predlog protokola izvođenja

- Koristiti isti tekst postavke i iste slike instrumenata PIC1.png do PIC5.png za sve modele u glavnom GO-6 poređenju.
- Za multimodalne modele zabeležiti da li su slike zaista priložene i da li model eksplicitno očitava vrednosti iz njih.
- Za tekstualne modele koristiti GO-6-old-simple-no-VI i rezultat jasno označiti kao bez vizuelnog sloja.
- Čuvati kompletan sirovi odgovor, runtime metapodatke, tok/s, ukupno vreme, broj tokena i podatak da li se Zig kod kompajlira.
- Ocenjivati zbirno po rubrikama, bez retroaktivnog menjanja metodologije zbog pojedinačnog modela.
- U tabelama rezultata odvojiti all runs od best by model, kao i kod GO-1 do GO-5.

14. Zaključak

GO-6 otvara novu oblast unutar REAL-AI-Benchmark pristupa: fizičko-AI benchmarkovanje. Njegova osnovna vrednost nije u tome što je zadatak veliki, nego u tome što je lanac obrade kompletan. Model mora da vidi, očita, proceni, simulira, odluči i verifikuje. To je mnogo bliže stvarnom tehničkom radu nego zadatak u kome su svi brojevi već savršeno digitalizovani.

Najvažnija poruka GO-6 testa jeste da inteligentno odlučivanje nije isto što i automatsko reagovanje na najveći alarm. Sistem može imati visok fuzzy rizik, a da najagresivnija akcija ipak bude pogrešna zbog sekundarnih posledica. Model koji to razume pokazuje viši nivo fizičko-sistenskog rezonovanja od modela koji samo prati prvu intuitivnu etiketu.

Zbog toga GO-6 predstavlja logičan nastavak GO-1 do GO-5 seta, ali i početak nove klase testova u kojima LLM/LMM sistemi moraju pokazati ne samo formalnu tačnost, nego i merenu fizičku pažnju, kauzalnu disciplinu i operativnu tehničku odgovornost.

Aneks A. Kanonska formulacija GO-6 prompta

GO-6 – Multimodalni fizičko-AI benchmark

Uz ovaj prompt priloženo je pet slika analognih instrumenata:

PIC1.png – temperatura T [$^{\circ}\text{C}$]

PIC2.png – pritisak P [kPa]

PIC3.png – protok F [L/min]

PIC4.png – vibracija V [mm/s]

PIC5.png – trend pritiska $D = dP/dt$ [kPa/min]

Traži se da prvo očitaš nominalne vrednosti i razumne intervale očitavanja. Nemoj tretirati analogni instrument kao savršeni digitalni senzor. Zatim sprovedi fuzzy inferenciju, dinamičku simulaciju četiri akcije kroz tri takta, klasifikaciju ishoda i izbor jedinstveno najbolje akcije. Konačno napiši Zig kod koji reprodukuje postupak i isporuči RESULTS_JSON.

Obavezne sekcije:

A-OCITAVANJE_ANALOGNIH_INSTRUMENATA

B-FIZICKA_KONZISTENTNOST

C-FUZZY_INFERENCIJA

D-DINAMICKA_SIMULACIJA

E-ODLUKA_I_DOKAZ_JEDINSTVENOSTI

F-ZIG_KOD

RESULTS_JSON

<END>

Aneks B. Referentni RESULTS_JSON

```
{
  "sensor_readings": {
    "T_C": 68.5,
    "P_kPa": 132.0,
    "F_L_min": 4.2,
    "V_mm_s": 5.6,
    "dPdt_kPa_min": 2.1
  },
  "reading_intervals": {
    "T_C": [68.0, 69.0],
    "P_kPa": [131.0, 133.0],
    "F_L_min": [4.0, 4.4],
    "V_mm_s": [5.4, 5.8],
    "dPdt_kPa_min": [1.9, 2.3]
  },
  "aggregated_risk": 0.85,
  "initial_fuzzy_decision": "EMERGENCY_MODE",
  "dynamic_outcomes": {
    "MONITOR": "catastrophic",
    "DERATE": "unstable",
    "CONTROLLED_RELIEF": "unstable",
    "EMERGENCY_MODE": "catastrophic"
  },
  "recommended_action": "CONTROLLED_RELIEF",
  "recommended_action_index": 2,
  "unique_best_action": true
}
```

Reference

1. Ivković, J. GO-1 do GO-5 — Metodologija benchmark seta. Radni promotivno-standardizacioni nacrt, REAL-AI-Benchmark.
2. Zadeh, L. A. (1965). Fuzzy sets. *Information and Control*, 8(3), 338–353. DOI: 10.1016/S0019-9958(65)90241-X.
3. Mamdani, E. H., & Assilian, S. (1975). An experiment in linguistic synthesis with a fuzzy logic controller. *International Journal of Man-Machine Studies*, 7(1), 1–13. DOI: 10.1016/S0020-7373(75)80002-2.
4. NIST. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). NIST AI 100-1.
5. ISO/IEC/IEEE 29119-1. Software and systems engineering — Software testing — Concepts and definitions.